Avaliação da Qualidade de Produto de Software

Khan Academy

Camila Silva Cavalcante
camilacsc08@gmail.com
Matrícula 232013944
Brazil

Enzo Menali Vettorato Toledo
enzomenali@gmail.com
Matrícula 241011054
Brazil

Geovanna Alves Umbelino
geovannaalves.u@gmail.com
Matrícula 232014450
Brazil

José Augusto Alves de Moraes
joseaugustomoraes@protonmail.com
Matrícula 231026429
Brazil

Luísa de Souza Ferreira
luisasouzalinda90@gmail.com
Matrícula 232014807
Brazil

Pedro Lucas Barbosa da Silva
21pedrolucas21@gmail.com
Matrícula 241025710
Brazil

Resumo

Este trabalho avalia a qualidade da plataforma web da Khan Academy segundo a família de normas ISO/IEC 25000 (SQuaRE), com foco em eficiência de desempenho, portabilidade e usabilidade, selecionadas por uma matriz ponderada com classificação MoSCoW. A especificação segue a abordagem *Goal Question Metric* (GQM), com três objetivos, 11 questões e 14 métricas, a serem aplicadas por testes externos de caixa-preta em navegadores de computador.

Abstract

This paper evaluates the quality of Khan Academy's web platform according to the ISO/IEC 25000 (SQuaRE) series, focusing on performance efficiency, portability, and usability, selected through a weighted matrix with MoSCoW classification. The specification follows the *Goal Question Metric* (GQM) approach, with three goals, 11 questions, and 14 metrics, to be applied through external black-box testing on desktop browsers.

CCS Concepts

• **Software and its engineering → Empirical software validation**; • **Human-centered computing → Usability testing**; **Accessibility design and evaluation methods**; • **Applied computing → E-learning**.

Keywords

SQuaRE, ISO/IEC 25010, GQM, Eficiência de Desempenho, Portabilidade, Usabilidade, Khan Academy

1 Introdução

O uso de plataformas digitais na educação tem ampliado as possibilidades de acesso ao conhecimento e de acompanhamento da aprendizagem. Entretanto, a adoção dessas ferramentas exige atenção à qualidade do software, especialmente em aspectos como desempenho, acessibilidade e adaptação a diferentes ambientes computacionais. Essas características são particularmente relevantes em contextos educacionais com limitações de infraestrutura tecnológica.

A Khan Academy é uma plataforma educacional que oferece videoaulas, exercícios interativos e recursos de acompanhamento do progresso dos estudantes. Considerando a diversidade de usuários e condições de acesso, torna-se importante avaliar se a plataforma apresenta características de qualidade adequadas às necessidades de estudantes, professores e responsáveis.

Diante desse cenário, este trabalho tem como objetivo avaliar a qualidade da versão web da Khan Academy, com foco em três características da **ISO/IEC 25010:2011 [1]: eficiência de desempenho, portabilidade e usabilidade.** A avaliação contempla comportamento temporal, utilização de recursos, adaptabilidade, acessibilidade e apreensibilidade, considerando os fluxos de navegação em cursos, reprodução de videoaulas, resolução de exercícios e consulta ao progresso do estudante.

Para conduzir a avaliação, adota-se o processo de avaliação de produtos de software da família SQuaRE [2, 3], utilizando a abordagem GQM para relacionar objetivos, questões e métricas, com referência à ISO/IEC 25023:2016 [4]. A investigação será realizada por meio de testes externos à plataforma web, com foco em comportamentos observáveis, buscando identificar limitações e oportunidades de melhoria fundamentadas nas evidências coletadas.

2 Referencial Teórico

2.1 Qualidade de Software e Modelo SQuaRE

A qualidade de software está relacionada à capacidade de um produto atender às necessidades e expectativas de seus usuários, considerando características que influenciam seu funcionamento e sua utilização. Para apoiar a avaliação dessas características, a família de normas ISO/IEC 25000, denominada *Systems and Software Quality Requirements and Evaluation* (SQuaRE) [2], estabelece modelos e diretrizes para a especificação e avaliação da qualidade de produtos de software.

Entre essas normas, a ISO/IEC 25010:2011 [1] apresenta um modelo de qualidade que permite organizar as características e subcaracterísticas a serem avaliadas. Complementarmente, a ISO/IEC 25023:2016 [4] estabelece medidas que auxiliam na obtenção de evidências quantitativas sobre a qualidade do produto, contribuindo para avaliações estruturadas e fundamentadas em critérios definidos.

2.2 Características de Qualidade

A ISO/IEC 25010:2011 [1] organiza a qualidade de produto em oito características, das quais três foram priorizadas neste estudo: eficiência de desempenho, portabilidade e usabilidade.

A eficiência de desempenho está relacionada ao comportamento do software quanto ao tempo de resposta e à utilização de recursos computacionais. A portabilidade considera a capacidade de adaptação do produto a diferentes ambientes de execução. Já a usabilidade

refere-se à capacidade de o sistema ser compreendido, aprendido e utilizado pelos usuários, incluindo aspectos de acessibilidade.

Essas características são relevantes para plataformas educacionais, pois permitem analisar fatores que podem influenciar o acesso aos conteúdos e a realização de atividades por usuários com diferentes necessidades e condições tecnológicas.

2.3 Abordagem Goal Question Metric (GQM)

A abordagem *Goal Question Metric*, apresentada por Basili, Caldiera e Rombach [5], propõe uma estrutura sistemática para a definição e interpretação de métricas de software. O método parte do estabelecimento de objetivos, que são desdobrados em questões e, posteriormente, associados a métricas capazes de fornecer evidências para respondê-las.

Essa organização permite relacionar os dados coletados aos propósitos da avaliação, evitando a seleção de medidas sem uma finalidade claramente definida. Além disso, favorece a rastreabilidade entre os objetivos de qualidade, as questões investigadas e os critérios utilizados para interpretar os resultados.

2.4 Trabalhos Relacionados

A avaliação de qualidade de software educacional já foi tratada em estudos anteriores. Soad e Barbosa [6] propõem o MoLEva, um método de avaliação de qualidade para aplicativos educacionais móveis que identifica pontos de melhoria e gera uma pontuação capaz de apoiar a comparação e a escolha entre aplicativos, avaliado por meio de um estudo de caso. Assim como neste trabalho, o resultado da avaliação é orientado a apoiar uma decisão de adoção.

No campo da acessibilidade, Souza, Cardoso e Perry [7] avaliaram uma plataforma brasileira de MOOCs com duas ferramentas automatizadas baseadas na WCAG. As ferramentas apresentaram resultados divergentes, não distinguiram as telas efetivamente vistas pelos estudantes das telas administrativas e não avaliaram materiais em vídeo, PDF ou língua de sinais. Os autores concluem que a verificação automatizada deve ser combinada com análise manual. Essa conclusão fundamenta a decisão deste estudo de usar a inspeção automatizada apenas como apoio e verificar manualmente, com teclado e leitores de tela, os fluxos centrais da Khan Academy.

3 Metodologia

A avaliação segue o processo de avaliação de produto da ISO/IEC 25040 [3], organizado em quatro fases: estabelecimento dos requisitos da avaliação, especificação, planejamento e execução. Este artigo apresenta as duas primeiras fases. O estudo concentra-se na plataforma web da Khan Academy acessada por navegadores em computadores e adota uma abordagem de caixa-preta, na qual são analisados apenas os comportamentos observáveis pela interface pública, sem acesso ao código-fonte ou à infraestrutura do serviço.

Na Fase 1, o propósito da avaliação foi definido a partir de um cenário hipotético de aplicação: a coordenação de uma escola pública que decide se recomenda a plataforma aos alunos e em quais condições de acesso. Desse cenário derivam quatro decisões apoiadas pela avaliação e as partes interessadas que influenciam as escolhas. A seleção das características usou uma matriz ponderada aplicada às oito características da ISO/IEC 25010:2011 [1], com três critérios pontuados de 1 a 3: impacto no aluno (peso 3), risco no contexto do cenário (peso 2) e viabilidade de produzir evidência externa (peso 1). A pontuação foi convertida em classes MoSCoW, e as características classificadas como *Must have* formaram a seleção. A mesma matriz foi aplicada às subcaracterísticas selecionadas para definir a profundidade de cada uma, e um teste de sensibilidade verificou se a ordem dependia dos pesos escolhidos. A fase também delimitou os fluxos, os ambientes de teste, a profundidade, os cortes de escopo, os limites de validade e a relação com os Objetivos de Desenvolvimento Sustentável (ODS).

Na Fase 2, a abordagem GQM [5] foi usada para derivar os objetivos de medição dos requisitos de avaliação da Fase 1. Foram definidos três objetivos, desdobrados em 11 questões, cada uma com uma hipótese, e 14 métricas adaptadas da ISO/IEC 25023:2016 [4], com definição de fórmula, fonte de dados, procedimento de coleta e critério de interpretação. Os resultados serão interpretados por uma escala ordinal comum de quatro níveis, e os critérios de acessibilidade têm como referência a WCAG 2.1 [8].

As Fases 3 e 4 compreendem o planejamento detalhado dos ensaios e a coleta e análise das medidas. Nos ensaios de acessibilidade, a inspeção automatizada será combinada com verificação manual, conforme recomendado por Souza, Cardoso e Perry [7]. Os resultados serão interpretados segundo os critérios de julgamento definidos na Fase 2, considerando as condições de execução e os limites de validade estabelecidos na Fase 1.

4 Fase 1 - Requisitos da Avaliação

4.1 Propósito e Uso Pretendido

Parte dos alunos que poderiam usar a Khan Academy estuda em condições desfavoráveis: computadores com poucos recursos, conexão lenta ou instável, sistemas operacionais variados e, em alguns casos, baixa visão ou outra necessidade de acessibilidade. Nessas condições, um conteúdo de boa qualidade pedagógica pode ficar inacessível na prática, porque a página demora a carregar, o vídeo trava, a interface não funciona no navegador disponível ou o leitor de tela não interpreta o exercício.

O propósito da avaliação é verificar se a plataforma web atende, com qualidade suficiente, alunos que estudam nessas condições, produzindo evidências para apoiar a decisão de adotá-la como apoio ao ensino. Para que o resultado apoie uma decisão concreta, adota-se um cenário hipotético: a coordenação de uma escola pública, cujos alunos usam computadores com sistemas diferentes, recursos limitados e conexão instável, decide se recomenda a Khan Academy e em quais condições de acesso. A Tabela 1 apresenta as decisões apoiadas pela avaliação e quem as toma.

Tabela 1: Decisões apoiadas pela avaliação

ID	Decisão	Quem decide
D1	Recomendar ou não a plataforma web nos computadores avaliados e indicar as condições de acesso observadas	Coordenação e professores
D2	Indicar a plataforma a alunos com baixa visão ou que usam leitor de tela, e com quais ajustes	Professores e responsáveis
D3	Planejar ou dispensar uma aula introdutória sobre o uso da plataforma	Professores
D4	Definir objetivos, questões, métricas e o rigor da avaliação	Equipe avaliadora

Os resultados serão publicados como relatório técnico de avaliação externa. Eles não constituem certificação de qualidade, não

comparam a Khan Academy com outras plataformas e não avaliam a qualidade do conteúdo pedagógico.

4.2 Requisitante e Partes Interessadas

O requisitante da avaliação é a coordenação da escola do cenário, que toma a decisão D1 e orienta a seleção de computadores, navegadores e condições de rede. A disciplina de Qualidade de Software atua como demandante acadêmico, definindo os critérios do trabalho e as restrições metodológicas. Os estudantes são os usuários primários, incluindo iniciantes, pessoas com baixa visão e usuários de tecnologia assistiva; suas necessidades fundamentam as decisões D1 a D3, os fluxos avaliados e a seleção das características. Professores e responsáveis são usuários de apoio: participam das decisões D1, D2 e D3, mas seus painéis permanecem fora dos ensaios. A equipe avaliadora toma a decisão D4, e suas limitações de ferramentas, participantes e equipamentos determinam os cortes e os limites de validade. A Khan Academy é fornecedora do produto e destinatária potencial dos achados, mas não influencia diretamente o estudo, pois não houve solicitação ou contato formal.

4.3 Produto e Contexto de Uso

A Khan Academy caracteriza-se como um produto de software educacional interativo disponibilizado como serviço *on-line*, cuja missão declarada é oferecer educação gratuita de alta qualidade a qualquer pessoa, em qualquer lugar [9]. Sob a perspectiva de avaliação externa caixa-preta, o contexto de uso modelado distingue dois níveis operacionais de atores: os *usuários primários*, constituídos por estudantes que realizam tarefas de estudo, consumo de videoaulas e resolução de exercícios interativos; e os *usuários de apoio*, compostos por docentes e responsáveis que organizam turmas, atribuem metas e acompanham o progresso discente.

Para assegurar a reprodutibilidade e a viabilidade dos ensaios, a fronteira de avaliação delimita-se à plataforma web executada em navegadores de computador. Excluem-se do escopo os aplicativos móveis nativos (Android e iOS), o acesso web por navegadores móveis, produtos derivados (Khan Academy Kids), ofertas institucionais (Khan Academy Districts), o assistente Khanmigo e soluções de distribuição local para ambientes desconectados (Kolibri).

O contexto operacional considerado reproduz as condições de computadores de laboratórios de informática ou residências no cenário de escolas públicas, contemplando restrições de conectividade, recursos de hardware limitados e requisitos de tecnologia assistiva, como contraste visual, navegação exclusiva por teclado e uso de leitores de tela.

4.4 Modelo de Qualidade

O modelo geral da ISO/IEC 25010:2011 [1] é abrangente e voltado a qualquer produto de software. Por isso, foi adaptado ao contexto da avaliação: características que exigem acesso ao código-fonte, testes de intrusão não autorizados ou observação prolongada do serviço foram descartadas, e, nas características mantidas, foram selecionadas apenas as subcaracterísticas que respondem às decisões D1 a D3. A Figura 1 apresenta o modelo adaptado.

4.5 Seleção e Priorização das Características

A seleção aplicou uma matriz ponderada às oito características da ISO/IEC 25010:2011. Cada característica recebeu notas de 1 a 3 em impacto no aluno, risco no contexto do cenário e viabilidade de produzir evidência externa, combinadas na pontuação $P = 3I + 2R + V$, com máximo de 18. O impacto recebeu o maior peso porque o propósito é apoiar decisões sobre os alunos, e a viabilidade o menor, para que a facilidade de medir não determine sozinha a seleção.

A pontuação foi convertida em classes MoSCoW: *Must have* para $P \geq 15$, *Should have* para $12 \leq P \leq 14$, *Could have* para $10 \leq P \leq 11$ e *Won't have* para $P \leq 9$. Uma característica com viabilidade 1 também é classificada como *Won't have*, pois a equipe não consegue produzir evidência sobre ela. A Tabela 2 apresenta o resultado.

Tabela 2: Seleção das características por MoSCoW com pesos

Característica	I	R	V	P	Classe
Eficiência de desempenho	3	3	3	18	*Must have*
Portabilidade	3	2	2	15	*Must have*
Usabilidade	3	2	2	15	*Must have*
Confiabilidade	2	2	1	11	*Won't have*
Adequação funcional	2	1	1	9	*Won't have*
Segurança	2	1	1	9	*Won't have*
Compatibilidade	1	1	2	7	*Won't have*
Manutenibilidade	1	1	1	6	*Won't have*

I: impacto no aluno (peso 3); R: risco no contexto (peso 2); V: viabilidade de evidência (peso 1).

A confiabilidade alcança 11 pontos, mas sua avaliação exigiria observação prolongada do serviço ou indução de falhas em produção, o que não é autorizado. Adequação funcional exigiria uma especificação de referência indisponível e se confunde com a avaliação do conteúdo pedagógico; segurança exigiria autorização para testes ativos; compatibilidade não responde às decisões D1 a D3; e manutenibilidade depende do código-fonte, que é proprietário.

Nas três características selecionadas, foram mantidas cinco subcaracterísticas. Ficaram de fora capacidade, que exigiria gerar carga no servidor; instalabilidade e substituibilidade, que não se aplicam a uma plataforma web; e reconhecimento de adequação, operabilidade, proteção contra erros do usuário e estética da interface, que não apoiam nenhuma decisão do cenário ou já estão parcialmente cobertas pela acessibilidade e pela apreensibilidade.

A mesma matriz definiu a prioridade das subcaracterísticas selecionadas: prioridade alta para $P \geq 15$ e média para $12 \leq P \leq 14$. Cada subcaracterística originou um requisito de avaliação, de R1 a R5, apresentado na Tabela 3 com a decisão apoiada e o objetivo GQM que dele deriva na Fase 2. As subcaracterísticas de prioridade alta recebem mais ambientes e repetições de medição; a apreensibilidade, de prioridade média, é avaliada com uma amostra exploratória.

Tabela 3: Priorização das subcaracterísticas e requisitos de avaliação

ID	Subcaracterística	I	R	V	P	Prior.	Dec.	Obj.
R1	Comportamento temporal	3	3	3	18	Alta	D1	G1
R2	Utilização de recursos	3	3	2	17	Alta	D1	G1
R3	Adaptabilidade	3	2	2	15	Alta	D1	G2
R4	Acessibilidade	3	2	2	15	Alta	D2	G3
R5	Apreensibilidade	2	2	2	12	Média	D3	G3

Como os pesos e as notas são critério da equipe, as pontuações foram recalculadas em dois cenários alternativos: com pesos iguais ($I + R + V$) e sem o critério de viabilidade ($3I + 2R$). Nos dois cenários,

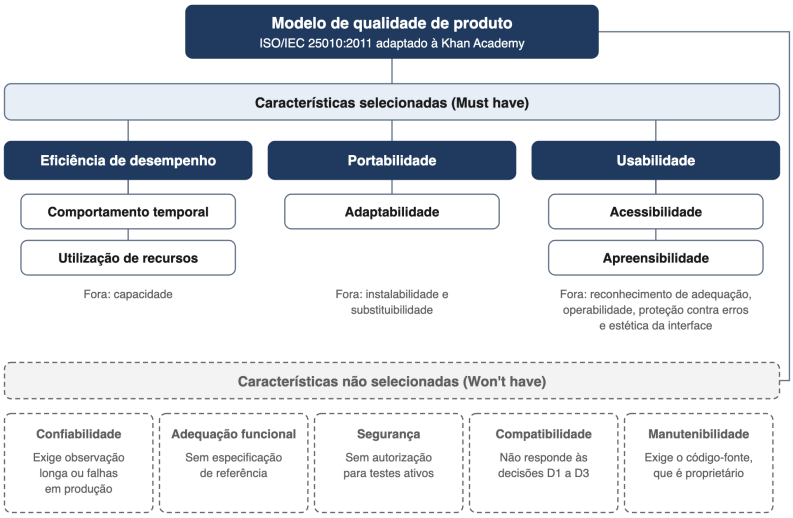


Figura 1: Modelo de qualidade adaptado da ISO/IEC 25010:2011 para a avaliação da Khan Academy

as três características selecionadas permanecem à frente das demais e a ordem das subcaracterísticas não se altera, o que indica que a seleção e a priorização não dependem de um ajuste fino dos pesos.

4.6 Escopo, Profundidade e Limites de Validade

O objeto da avaliação é a plataforma web acessada por navegadores em computadores, observada como caixa-preta. Os ensaios usam quatro fluxos: navegação em cursos (FL1), reprodução de videoaulas (FL2) e resolução de exercícios (FL3), que formam a jornada central de estudo e recebem maior profundidade, e consulta ao progresso do estudante (FL4), considerado secundário. A autenticação é apenas precondição, realizada com uma conta de teste controlada pela equipe.

Em vez de combinar todos os sistemas e navegadores, foram definidos quatro ambientes com finalidade específica, que cobrem os três motores de renderização (Blink, Gecko e WebKit): A1, Windows com Chrome, ambiente de referência, com NVDA, teclado, zoom de 200% e alto contraste; A2, Windows com Firefox, com teclado; A3, macOS com Safari, com VoiceOver e teclado; e A4, Ubuntu LTS com Firefox, com Orca e teclado. Windows e macOS são executados em computadores reais; o Ubuntu pode ser executado em computador real ou em máquina virtual, com a modalidade e os recursos registrados antes da coleta. Comportamento temporal e utilização de recursos são medidos apenas no ambiente de referência A1, com uma execução de aquecimento e cinco repetições válidas por tarefa, em conexão sem limitação artificial e em um perfil controlado de conexão limitada. A adaptabilidade é verificada nos quatro ambientes, nas resoluções de 1366 por 768 e 1920 por 1080 pixels. A acessibilidade combina navegação por teclado e leitores de tela nos ambientes A1, A3 e A4, com inspeções de zoom e alto contraste em A1 e inspeção automatizada apenas como apoio. A apreensibilidade é observada com três a cinco participantes adultos sem experiência prévia com a plataforma.

Ficam fora do escopo os aplicativos nativos, os navegadores móveis, os painéis de professores, responsáveis e administradores, a infraestrutura interna e as APIs não documentadas, os testes ativos de segurança, os testes de carga e disponibilidade dos servidores e a qualidade pedagógica do conteúdo. Os resultados valem apenas para os fluxos, versões, computadores, condições de rede e tecnologias assistivas efetivamente avaliados; os ensaios de acessibilidade não comprovam conformidade integral com a WCAG [8], e a amostra de apreensibilidade não representa estatisticamente os estudantes de escolas públicas.

4.7 Relação com os Objetivos de Desenvolvimento Sustentável

O estudo relaciona-se de forma contextual com o ODS 4, Metas 4.5 e 4.a, e com o ODS 10, Meta 10.2 [10, 11, 12]. A Meta 4.5 trata da eliminação de disparidades e do acesso à educação para grupos vulneráveis, incluindo pessoas com deficiência; os ensaios de acessibilidade e apreensibilidade podem identificar barreiras técnicas ao localizar conteúdos, assistir a aulas e resolver exercícios. A Meta 4.a trata de instalações de ensino inclusivas, e seu indicador 4.a.1 mede a proporção de escolas com computadores, internet e materiais adaptados para estudantes com deficiência, condição que o cenário pressupõe. A Meta 10.2 trata da inclusão social e econômica, e os ensaios de eficiência e adaptabilidade em computadores e conexões limitados podem revelar barreiras técnicas de acesso. Essa relação é contextual: a avaliação caracteriza a qualidade do software e não mede os indicadores oficiais de educação, renda ou inclusão.

5 Fase 2 - Especificação da Avaliação

5.1 Objetivos GQM

Os objetivos de medição foram definidos a partir dos requisitos de qualidade priorizados na Fase 1, contemplando eficiência de desempenho, portabilidade e usabilidade. A especificação seguiu a abordagem GQM, considerando cinco elementos: objeto de análise, propósito, foco de qualidade, ponto de vista e contexto. A partir

dessa estrutura, foram estabelecidos três objetivos, associados às características e subcaracterísticas selecionadas.

5.1.1 G1 - Eficiência de Desempenho. O objetivo G1 visa avaliar o desempenho observável dos fluxos de navegação em cursos (FL1), videoaulas (FL2) e exercícios (FL3) da Khan Academy, considerando o comportamento temporal e a utilização de recursos computacionais. A análise contempla a perspectiva de estudantes, professores, coordenação escolar e responsáveis, em ambientes web com configurações de hardware e condições de rede documentadas. Esse objetivo está associado aos requisitos R1 e R2, às questões Q1 a Q4 e às métricas M1 a M5.

5.1.2 G2 - Portabilidade. O objetivo G2 concentra-se na avaliação da adaptabilidade da Khan Academy aos ambientes computacionais contemplados pelo estudo. São considerados os fluxos FL1 a FL4, sob a perspectiva de estudantes, professores e coordenação escolar. A investigação abrange a execução dessas funcionalidades nas combinações viáveis de navegadores e sistemas operacionais de computadores definidas no escopo. O objetivo corresponde ao requisito R3, às questões Q5 e Q6 e às métricas M6 e M7.

5.1.3 G3 - Usabilidade. O objetivo G3 busca avaliar as condições de utilização da plataforma, com ênfase na acessibilidade e na apreensibilidade dos fluxos de navegação em cursos, videoaulas e exercícios (FL1 a FL3). A análise considera estudantes com baixa visão ou que utilizam leitores de tela, estudantes sem experiência prévia com a plataforma, professores e responsáveis. O contexto de avaliação compreende a versão web da Khan Academy, incluindo a utilização de recursos de navegação por teclado e tecnologias assistivas compatíveis com os ambientes selecionados, além de procedimentos relacionados à aprendizagem da interface. Esse objetivo está associado aos requisitos R4 e R5, às questões Q7 a Q11 e às métricas M8 a M14.

A definição desses objetivos estabelece a rastreabilidade entre os requisitos de qualidade e os elementos de medição, fornecendo a base para a especificação das questões, hipóteses e métricas da avaliação.

5.2 Questões e Hipóteses

Os três objetivos foram desdobrados em 11 questões (Q1 a Q11), cada uma associada a uma hipótese de mesmo número (H1 a H11) e respondida por ao menos uma métrica (Tabelas 4 a 7). As questões investigam se os fluxos permanecem utilizáveis nas condições do cenário escolar, sem antecipar fórmulas de cálculo. As hipóteses explicitam o resultado esperado, o ambiente em que será verificado e o limite adotado. Todas são suposições de trabalho formuladas antes da coleta e propostas para ratificação da equipe, e não representam resultados observados.

Nas hipóteses, A1 a A4 designam os ambientes do estudo: Windows com Chrome (A1), Windows com Firefox (A2), macOS com Safari (A3) e Ubuntu com Firefox (A4). FL1 a FL4 designam os fluxos de navegação em cursos, videoaulas, exercícios e consulta ao progresso pelo próprio estudante. Eficiência de desempenho, ampliação, alto contraste e apreensibilidade são avaliadas apenas em A1, ambiente de referência. Teclado e leitor de tela são avaliados em A1, A3 e A4, e a adaptabilidade, nos quatro ambientes.

5.2.1 G1 – Eficiência de Desempenho. Q1 trata da espera percebida pelo estudante, enquanto Q2, Q3 e Q4 separam CPU, memória e dados de rede porque cada recurso pode limitar o uso de forma independente em computadores e conexões restritos. H1 a H4 restringem-se a A1, onde os recursos serão monitorados. H1 considera duas condições de rede, uma sem limitação artificial e outra com perfil controlado de conexão limitada, que representa a preocupação do cenário escolar com a conectividade.

Tabela 4: Questões e hipóteses de G1 – Eficiência de Desempenho

Q	Questão e hipótese	Métricas
Q1	*A espera por carregamentos, início de videoaulas e respostas de exercícios permite continuar a atividade sem interrupções?* H1: em A1, para cada etapa de FL1 a FL3 e condição de rede, a mediana do tempo de resposta será de até 3 s e pelo menos 90% das tentativas elegíveis serão concluídas, sem bloqueio atribuível à plataforma.	M1, M2
Q2	*Os fluxos podem ser concluídos sem sobrecarregar o processamento do computador de referência?* H2: em A1, a utilização média de CPU será de até 50% em cada execução válida de FL1 a FL3, sem interrupção atribuível à sobrecarga.	M3
Q3	*Os fluxos permanecem utilizáveis dentro da memória disponível?* H3: em A1, o pico de memória será de até 1.024 MiB em cada execução válida de FL1 a FL3, sem interrupção atribuível ao esgotamento de memória.	M4
Q4	*O volume de dados do trecho padronizado de navegação é compatível com o orçamento de acesso?* H4: em A1, cada execução concluída do trecho padronizado, com política de cache constante, transferirá no máximo 10 MiB, somando envio e recebimento.	M5

A verificação exige que o tempo pedagógico de assistir à videoaula ou resolver o exercício seja excluído de M1, que falhas e interrupções sejam registradas à parte e que M5 considere apenas execuções concluídas, com a mesma política de cache e sem transferência integral de vídeos. Como H3 trata de picos, médias ou medianas de memória não podem ocultar violações individuais. A coincidência entre CPU elevada e interrupção não demonstra relação de causa isoladamente, e a classificação segue o protocolo de evidências.

5.2.2 G2 – Portabilidade. Q5 verifica se os fluxos são concluídos entre sistemas operacionais e navegadores, e Q6 se conteúdo e controles se preservam nas resoluções de referência. Ambas usam o mesmo patamar de 90% das combinações selecionadas, mas são contadas separadamente, de modo que um mesmo resultado não seja computado duas vezes.

O protocolo deve distinguir a preparação normal do ensaio de um ajuste extraordinário na plataforma. Combinações inviáveis por incompatibilidade conhecida entre ferramentas e sistemas são tratadas no planejamento e não contam automaticamente como falha da Khan Academy.

Tabela 5: Questões e hipóteses de G2 – Portabilidade

Q	Questão e hipótese	Métricas
Q5	*Os fluxos essenciais são concluídos nas combinações de sistema operacional e navegador, sem ajustes extraordinários na plataforma?* H5: pelo menos 90% das combinações de ambiente (A1 a A4) e fluxo (FL1 a FL4) selecionadas permitirão concluir o roteiro e alcançar o resultado esperado, sem alterar a plataforma.	M6
Q6	*Conteúdo e controles necessários permanecem utilizáveis nas resoluções avaliadas?* H6: em pelo menos 90% das combinações essenciais de ambiente, resolução (1366×768 e 1920×1080) e fluxo, as tarefas serão concluídas com acesso a todas as informações e controles do roteiro.	M7

5.2.3 G3 – Usabilidade. Q7 a Q10 abordam a acessibilidade por teclado, leitor de tela, ampliação e contraste, tendo como referência critérios aplicáveis da WCAG 2.1 [8]. Em H7, a conclusão ocorre sem substituir o teclado pelo mouse durante a tarefa. Em H8, o resultado depende do anúncio das informações e da identificação dos controles, e não apenas da presença de rótulos. Q9 difere de Q6: avalia a ampliação do conteúdo (zoom de 200%), e não a mudança do tamanho da janela. H10 reúne dois ramos independentes, porque o alto contraste do Windows não substitui a verificação das razões de contraste.

As questões e hipóteses de G3 estão distribuídas nas Tabelas 6 e 7.

Tabela 6: Questões e hipóteses de G3: teclado, leitor de tela e ampliação

Q	Questão e hipótese	Métricas
Q7	*Quem usa apenas teclado consegue identificar e acionar os controles necessários, sem bloqueios?* H7: em pelo menos 90% das combinações de tarefa e ambiente (A1, A3 e A4) para FL1 a FL3, a tarefa será concluída apenas por teclado, com foco visível e sem bloqueios de navegação.	M8
Q8	*Quem usa leitor de tela recebe as informações necessárias e consegue concluir os fluxos?* H8: em pelo menos 90% das combinações com NVDA (A1), VoiceOver (A3) e Orca (A4), o leitor anunciará as informações e identificará os controles definidos no *checklist*, permitindo concluir a tarefa sem consulta visual.	M9
Q9	*A ampliação permite continuar lendo o conteúdo e operando os controles, sem perda de informação ou funcionalidade?* H9: em A1, a 1366×768, pelo menos 90% das tarefas essenciais serão concluídas com zoom de 200%, sem perda das informações ou dos controles necessários.	M10

Q11 aborda a apreensibilidade em caráter exploratório, com três a cinco participantes adultos sem experiência anterior com a plataforma. H11 considera apenas a primeira tentativa de cada par participante–tarefa, após instrução inicial padronizada. M12 é a métrica principal de Q11, e M13 (erros) e M14 (tempo) a complementam, pois uma tarefa concluída autonomamente pode ainda indicar dificuldade de aprendizagem. Se o recrutamento não for possível, o resultado será apresentado como inspeção exploratória da equipe, e não como evidência sobre estudantes.

Tabela 7: Questões e hipóteses de G3: contraste e apreensibilidade

Q	Questão e hipótese	Métricas
Q10	*A apresentação visual permite distinguir informações e controles, inclusive em alto contraste?* H10: (a) todos os textos aplicáveis inspecionados atenderão ao contraste mínimo de 4,5:1 (texto comum) e 3:1 (texto grande), e (b) em A1, pelo menos 90% das tarefas essenciais serão concluídas com o alto contraste do Windows ativado, sem desativá-lo.	M11
Q11	*Estudantes novos conseguem iniciar e concluir as tarefas essenciais após a instrução inicial, sem orientação adicional?* H11: em A1, pelo menos 90% das primeiras tentativas elegíveis de cada tarefa essencial, e do conjunto avaliado, serão concluídas por participantes adultos novos na plataforma, após instrução inicial padronizada e sem ajuda.	M12, M13, M14

5.2.4 Fundamentação e Verificação das Hipóteses. As hipóteses derivam dos requisitos R1 a R5 e das restrições do escopo. Os limites quantitativos, como 3 s em H1, 50% em H2, 1.024 MiB em H3, 10 MiB em H4 e 90% nas demais, são critérios operacionais propostos pelo estudo, e não valores normativos da ISO/IEC 25023 [**iso25023_2016**]. Eles devem ser ratificados pela equipe antes da coleta. A interpretação de cada hipótese confronta os dados válidos com o seu enunciado, e não apenas com a pontuação da métrica, e resulta em um de três estados:

- **Sustentada na amostra:** os dados válidos, com cobertura suficiente, atendem integralmente à expectativa.
- **Não sustentada na amostra:** os dados válidos e suficientes não atendem à expectativa, e a divergência é acompanhada da evidência.
- **Inconclusiva:** faltam parâmetros fundamentados, dados válidos ou cobertura necessária. Achados parciais permanecem registrados.

Os resultados valem apenas para os fluxos, ambientes e condições efetivamente avaliados e serão obtidos na etapa de coleta.

5.3 Métricas de Avaliação

As métricas foram definidas com base na abordagem *Goal-Question-Metric* (GQM), considerando as características de qualidade selecionadas para a avaliação da plataforma Khan Academy, em sua versão web, e a ISO/IEC 25023:2016 [4] como referência para a especificação das medidas.

Foram estabelecidas 14 métricas (M1 a M14), distribuídas entre três objetivos: eficiência de desempenho (G1), portabilidade (G2) e usabilidade (G3). A Tabela 8 apresenta os indicadores propostos e sua associação às questões GQM, e a Figura 2 apresenta a hierarquia entre objetivos, questões e métricas.

A coleta será realizada em ambientes e fluxos previamente definidos, utilizando registros de execução, instrumentos de monitoramento e verificações de acessibilidade. Os resultados quantitativos serão complementados pelo registro de falhas e barreiras que comprometam funcionalidades essenciais.

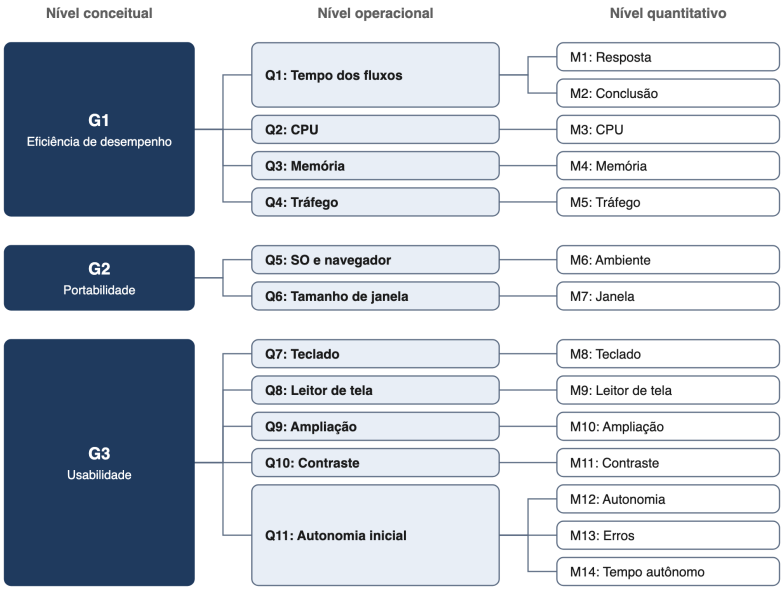


Figura 2: Hierarquia GQM: objetivos G1 a G3, questões Q1 a Q11 e métricas M1 a M14

Tabela 8: Métricas de avaliação da Khan Academy

Obj.	Métrica	Indicador	Q.
G1	M1: Resposta	Mediana/P90 (s)	Q1
G1	M2: Conclusão	Sucesso (%)	Q1
G1	M3: CPU	Média (%)	Q2
G1	M4: Memória	Pico (MiB)	Q3
G1	M5: Tráfego	Volume (MiB)	Q4
G2	M6: Ambiente	Sucesso (%)	Q5
G2	M7: Janela	Adequação (%)	Q6
G3	M8: Teclado	Conclusão (%)	Q7
G3	M9: Leitor de tela	Conclusão (%)	Q8
G3	M10: Ampliação	Adequação (%)	Q9
G3	M11: Contraste	Conformidade (%)	Q10
G3	M12: Autonomia	Conclusão (%)	Q11
G3	M13: Erros	Taxa (%)	Q11
G3	M14: Tempo autônomo	Mediana (s)	Q11

5.4 Critérios de Julgamento

Para interpretar as medições, adotou-se uma escala ordinal de quatro níveis: Excelente (3), Alvo (2), Mínimo aceitável (1) e Inaceitável (0). Resultados sem evidências suficientes serão classificados como inconclusivos.

As métricas percentuais de sucesso incluem M2 (conclusão de fluxos), M6 (execução por ambiente), M7 (adaptação ao tamanho da janela), M8 (navegação por teclado), M9 (uso de leitor de tela), M10 (ampliação de conteúdo) e M12 (conclusão autônoma). Os níveis correspondentes são apresentados na Tabela 9.

Tabela 9: Critérios para métricas percentuais

Nível	M2, M6 a M10, M12	M13
Excelente (3)	100%	0%
Alvo (2)	$[90, 100)\%$	$(0, 10]\%$
Mínimo (1)	$[75, 90)\%$	$(10, 25]\%$
Inaceitável (0)	$< 75\%$	$> 25\%$

Tabela 10: Critérios para tempo e recursos

Métrica	3	2	1	0
M1 (s)	≤ 1	$(1, 3]$	$(3, 10]$	> 10
M3 (%)	≤ 25	$(25, 50]$	$(50, 75]$	> 75
M4 (MiB)	≤ 512	$(512, 1024]$	$(1024, 2048]$	> 2048
M5 (MiB)	≤ 5	$(5, 10]$	$(10, 20]$	> 20
M14 (s)	≤ 60	$(60, 120]$	$(120, 180]$	> 180

Para as métricas temporais e de utilização de recursos, valores menores representam resultados mais favoráveis. A Tabela 10 apresenta os limites operacionais estabelecidos.

A avaliação de acessibilidade considera requisitos aplicáveis da WCAG 2.1 [8]. Para M10, será verificada a preservação do conteúdo e das funcionalidades durante a ampliação, incluindo o redimensionamento de texto até 200%. Para M11, serão considerados os limites de contraste do nível AA (4,5:1 para textos comuns e 3:1 para textos grandes) e do nível AAA (7:1 e 4,5:1, respectivamente). Em M11, o atendimento aos limites AA corresponde ao nível Alvo (2), enquanto o atendimento aos limites AAA corresponde ao nível Excelente (3). Falhas restritas a elementos não essenciais ou que comprometam elementos essenciais recebem, respectivamente, pontuações 1 e 0.

As métricas M8 e M9 também consideram as barreiras identificadas na navegação por teclado e na utilização de leitores de tela, sem que os percentuais obtidos impliquem conformidade integral com a WCAG.

Os limites quantitativos constituem critérios operacionais propostos para o estudo, não valores normativos da ISO/IEC 25023. A aplicação pressupõe a padronização dos ambientes e fluxos, sendo M5 restrita à navegação sem transferência integral de vídeos e M14 a tarefas curtas não pedagógicas.

Uma questão GQM será considerada atendida quando suas métricas principais alcançarem pontuação igual ou superior a 2, desde

que não existam bloqueios em funcionalidades essenciais. O atendimento de cada objetivo dependerá do resultado de suas questões, enquanto as hipóteses serão examinadas com base nas evidências coletadas.

6 Conclusão

Este trabalho apresentou as duas primeiras fases da avaliação de qualidade da plataforma web da Khan Academy, conduzida segundo o processo de avaliação da família SQuaRE [3]. Na Fase 1, o propósito foi associado a um cenário de aplicação e a quatro decisões com responsáveis definidos; as características foram selecionadas por uma matriz ponderada convertida em classes MoSCoW, resultando em eficiência de desempenho, portabilidade e usabilidade; e o escopo foi delimitado a quatro fluxos e quatro ambientes, com limites de validade explícitos e relação contextual com os ODS 4 e 10. Na Fase 2, os cinco requisitos de avaliação foram desdobrados, pela abordagem GQM [5], em três objetivos, 11 questões e 14 métricas, com critérios de julgamento em uma escala comum.

A principal contribuição desta etapa é a rastreabilidade entre o propósito, as decisões, os requisitos, os objetivos de medição e os critérios de julgamento, que permite interpretar os resultados futuros em relação às decisões que eles devem apoiar. O teste de sensibilidade mostrou que a seleção e a priorização não dependem do ajuste fino dos pesos definidos pela equipe.

O estudo tem limitações que orientarão a interpretação dos resultados: a avaliação é externa e de caixa-preta, o desempenho será medido em um único computador de referência, a amostra de apreensibilidade é exploratória e os limiares quantitativos são propostas metodológicas da equipe, e não valores normativos. Como próximos passos, as Fases 3 e 4 detalharão o plano de execução dos ensaios, realizarão a coleta das medidas nos ambientes definidos e analisarão os resultados à luz das hipóteses e dos critérios de julgamento, resultando em recomendações para a adoção da plataforma no cenário considerado.

Referências

[1] 2011. Systems and software engineering – Systems and software Quality Requirements and Evaluation (SQuaRE) – System and software quality models. Standard. International Organization for Standardization (ISO).

[2] 2014. Systems and software engineering – Systems and software Quality Requirements and Evaluation (SQuaRE) – Guide to SQuaRE. Standard. International Organization for Standardization (ISO).

[3] International Organization for Standardization and International Electrotechnical Commission. 2011. ISO/IEC 25040:2011: systems and software engineering - systems and software quality requirements and evaluation (SQuaRE) - evaluation process. Genebra, (2011). Retrieved 26 de out. de 2026 from https://www.iso.org/standard/35765.html.

[4] 2016. Systems and software engineering – Systems and software Quality Requirements and Evaluation (SQuaRE) – Measurement of system and software product quality. Standard. International Organization for Standardization (ISO).

[5] Victor R. Basili, Gianluigi Caldiera e H. Dieter Rombach. 1994. The goal question metric approach. Em *Encyclopedia of Software Engineering*. John Wiley & Sons, 528–532. Retrieved 17 de out. de 2026 from https://www.cs.umd.edu/users/mvz/handouts/gqm.pdf.

[6] Gustavo W. Soad e Ellen F. Barbosa. 2017. MoLEva: um método de avaliação de qualidade para aplicativos educacionais móveis. Em *Anais do XVI Simpósio Brasileiro de Qualidade de Software (SBQS)*. Sociedade Brasileira de Computação, Rio de Janeiro, 74–88. doi:10.5753/sbqs.2017.15093.

[7] Napoliana Souza, Eduardo Cardoso e Gabriela Trindade Perry. 2019. Limitações da avaliação automatizada de acessibilidade em uma plataforma de MOOCs: estudo de caso de uma plataforma brasileira. *Revista Brasileira de Educação Especial*, 25, 4. doi:10.1590/s1413-65382519000400005.

[8] World Wide Web Consortium. 2025. Web content accessibility guidelines (WCAG) 2.1. W3C. Retrieved 26 de out. de 2026 from https://www.w3.org/TR/WCAG21/.

[9] Khan Academy. 2026. About us. Retrieved 20 de out. de 2026 from https://www.khanacademy.org/about.

[10] United Nations Statistics Division. 2026. Sustainable development goal indicators: target 4.5. Retrieved 26 de out. de 2026 from https://unstats.un.org/sdgs/metadata/?Goal=4&Target=4.5.

[11] United Nations Statistics Division. 2026. Sustainable development goal indicators: target 4.a. Retrieved 26 de out. de 2026 from https://unstats.un.org/sdgs/metadata/?Goal=4&Target=4.a.

[12] United Nations Statistics Division. 2026. Sustainable development goal indicators: target 10.2. Retrieved 26 de out. de 2026 from https://unstats.un.org/sdgs/metadata/?Goal=10&Target=10.2.

A Contribuição dos Integrantes

A Tabela 11 apresenta a contribuição de cada integrante nas atividades da Entrega 1.

Tabela 11: Contribuição dos integrantes na Entrega 1

Matrícula	Integrante	Participação	Porcentagem de Contribuição
232013944	Camila Silva Cavalcante	Questões e hipóteses; Níveis de pontuação e critérios de julgamento; Hierarquia e representação gráfica GQM	16,6%
241011054	Enzo Menali Vettorato Toledo	Caracterização do produto; Contexto de uso; Stakeholders e perfis de estudantes	16,6%
232014450	Geovanna Alves Umbelino	Objetivos de medição; Especificação das métricas; Níveis de pontuação e critérios de julgamento; Hierarquia e representação gráfica GQM	16,7%
231026429	José Augusto Alves de Moraes	Escopo e objetos da avaliação; Ambientes de teste; Alinhamento com as ODS	16,6%
232014807	Luísa de Souza Ferreira	Propósito, uso pretendido, modelo de qualidade e priorização das características, Referencial Teórico e Metodologia	16,8%
241025710	Pedro Lucas Barbosa da Silva	Gestão PSM/CID; Organização e planejamento das issues; Estruturação do artigo; Revisão e Padronização do Pages	16,7%
		Total	100%